[STATE: STABLE] | [AUDIT: READY]

ForjaMCP: Soberanía Agéntica Local-First

Technical Disclosure & Architecture Deep Dive (2026).

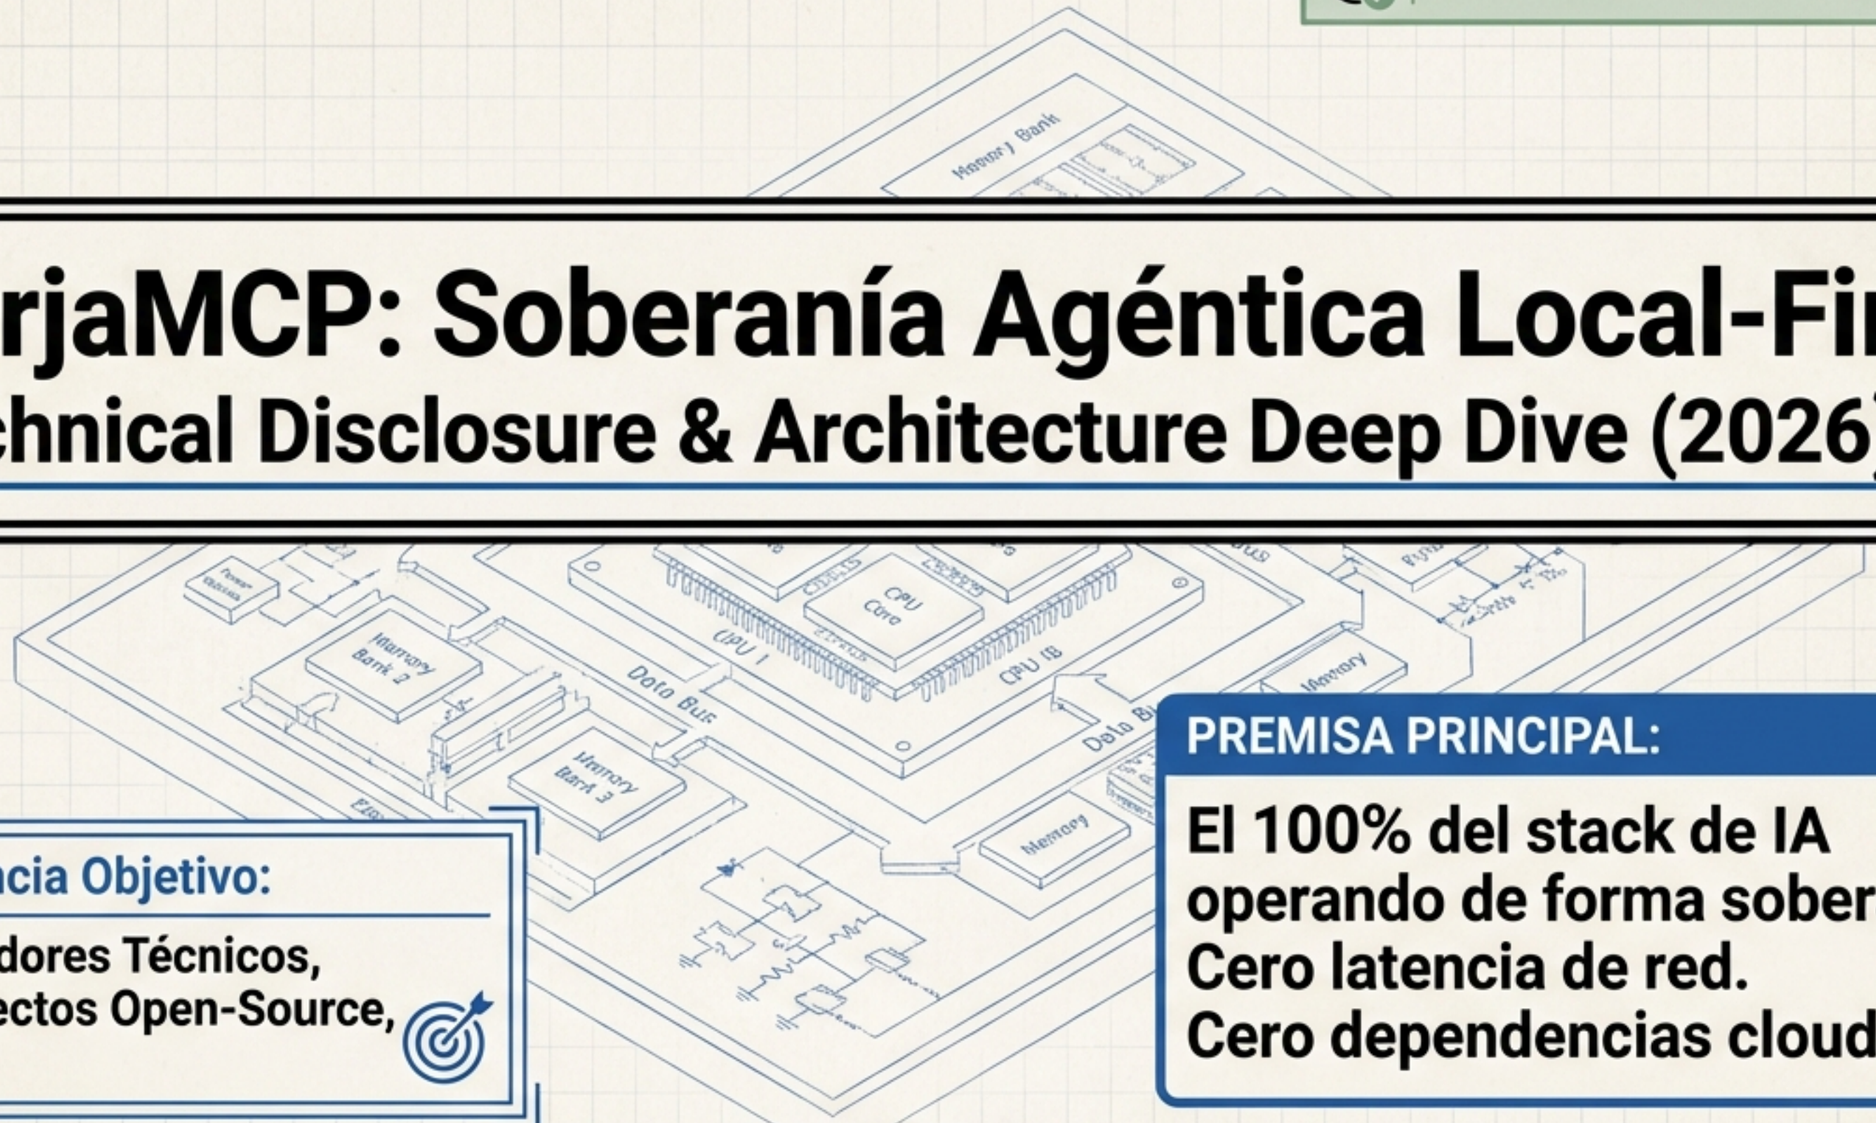

Audiencia Objetivo:

Evaluadores Técnicos, Arquitectos Open-Source, CTOs.

PREMISA PRINCIPAL:

El 100% del stack de IA operando de forma soberana. Cero latencia de red. Cero dependencias cloud.

AUDITORÍA CLASIFICADA
FECHA: 01.10.2026

DOCUMENTO CONFIDENCIAL - NIVEL 4

NotebookLM

El Freno de Mano Invisible de la IA

El Paradigma "Chat-as-a-Service"

Los modelos en la nube obligan a que cada llamada a herramienta (tool call) viaje cientos de kilómetros.

Añade 120-220ms por acción.
Compromete la soberanía de los datos.
Costo: $120-$250/mes por cómputo alquilado.

Soberanía Local

Para un humano, el retraso es imperceptible.
Para un agente autónomo, la latencia de red es un cuello de botella inaceptable.

NotebookLM

El Cambio de Paradigma: Local-First Agentic OS

No es un wrapper. No es un SDK. ForjaMCP es una infraestructura central para ejecutar IA directamente en tu máquina.

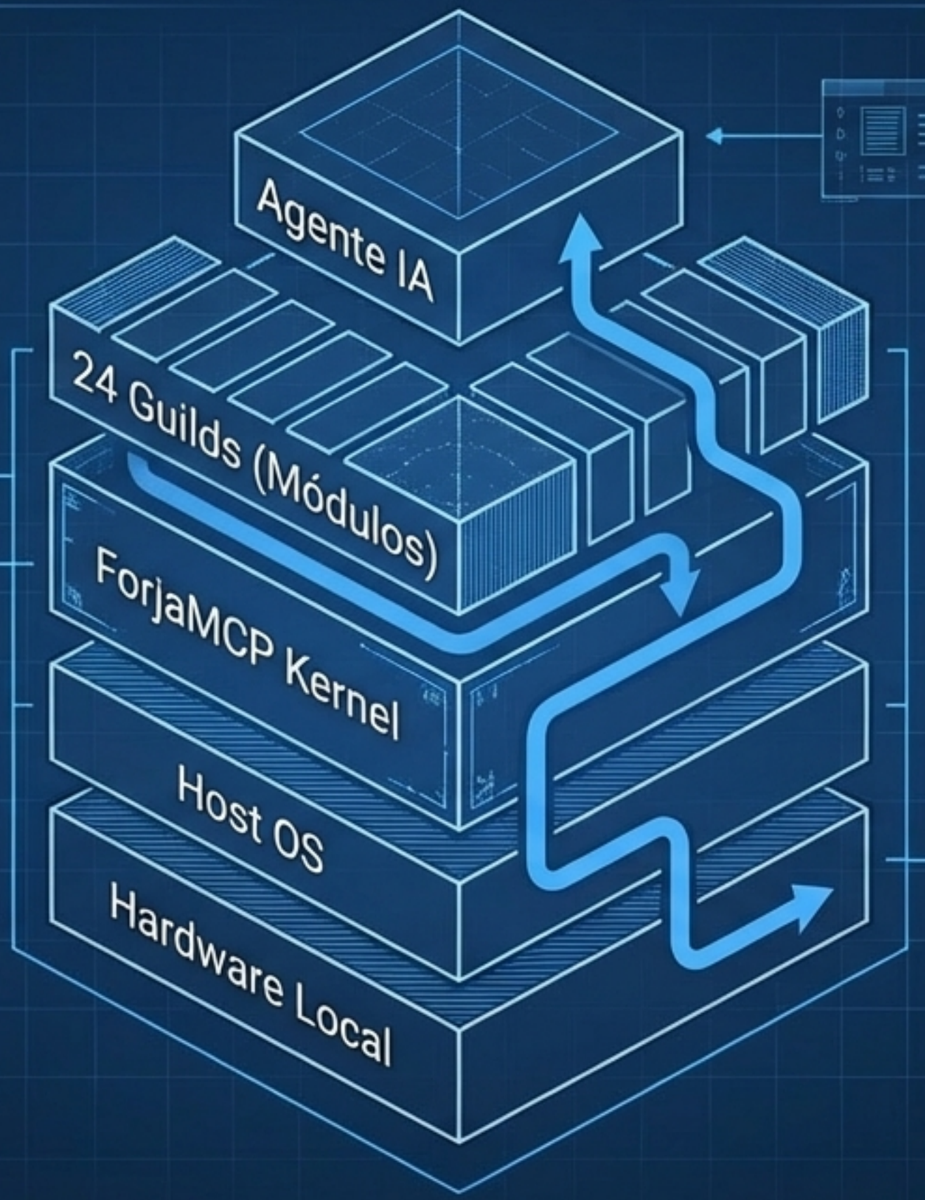

MCP como ISA:
El Model Context Protocol no se usa como simple API, sino como la arquitectura de conjunto de instrucciones (Instruction Set Architecture) base.

Soberanía de Compute:
No solo controlas dónde se almacenan los datos, controlas el 100% de la ejecución. Cero salida a internet requerida.

NotebookLM

La Evidencia del Rendimiento

Comparativa de Latencia Promedio por Tool Call (ms)

Comparativa Multidimensional: ForjaMCP vs Sistemas Cloud

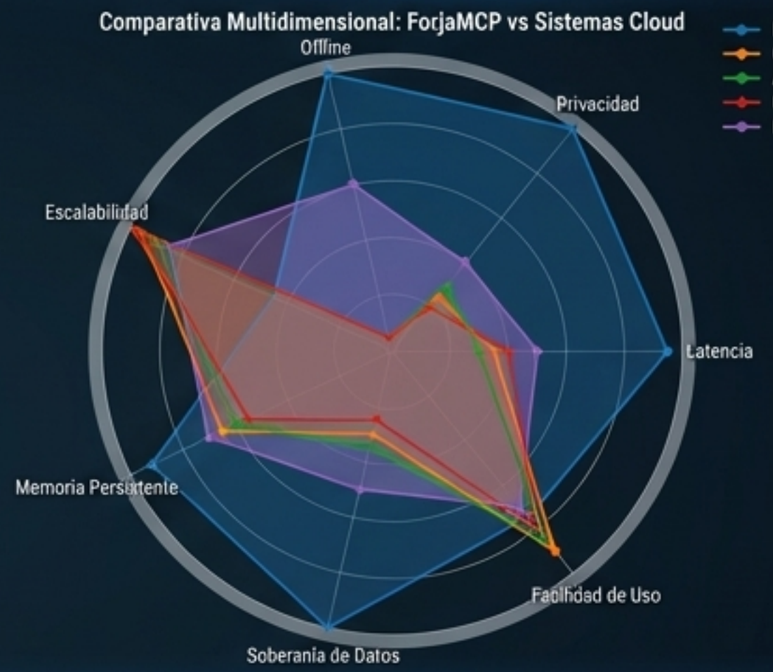

Matriz de Diagnóstico

ForjaMCP:	3ms Latencia	$6/mes (Energía)	100% Privacidad	100% Offline
OpenAI/Claude/Google:	120-220ms Latencia	$120-$250/mes	Baja Privacidad	0% Offline

**60-70x más rápido en invocación de herramientas. Optimizado para soberanía en máquina única (*Single-Machine Optimized*).

NotebookLM

Arquitectura Core: El Micro-Kernel MCP

Stdio
Integración directa con IDEs (Claude Desktop, Cursor).

Streamable HTTP
Soporte stateful para sesiones modernas.

Legacy SSE
Compatibilidad retroactiva.

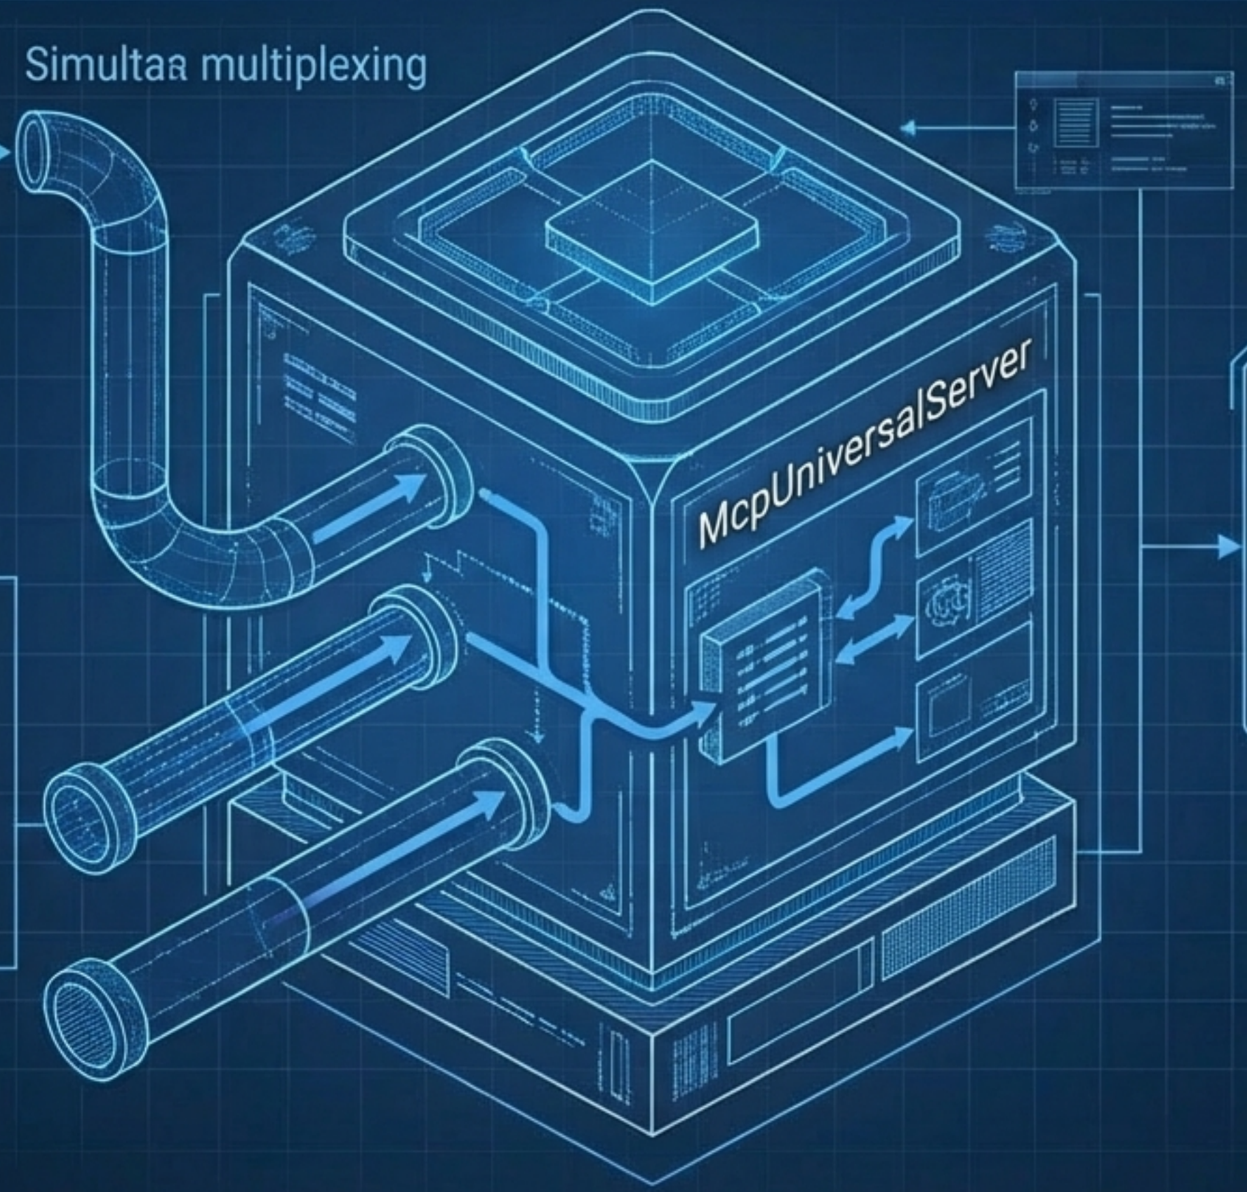

El corazón del sistema habla MCP de forma nativa. Un diseño de kernel limpio que consolida interfaces dispares en un solo bus de comunicación sin bloqueos.

NotebookLM

El Ecosistema de Gremios (Guilds)

24 Módulos de Capacidad Type-Safe

Builders (14)
Actúan sobre el mundo real.

Scholars (7)
Análisis y cognición profunda.

Watchers (3)
Observabilidad y automatización continua.

NotebookLM

Optimización de Recursos: Lazy Loading & Routing

Lazy Loading & Auto-Unload

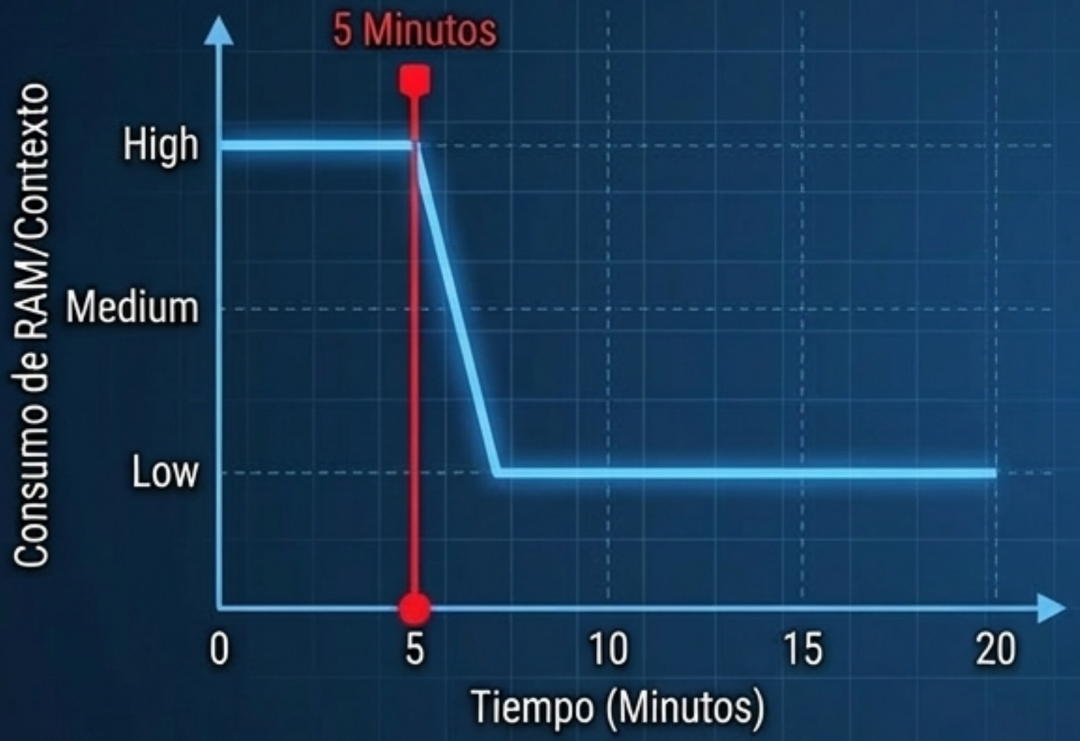

Solo 'bash_expert' y 'memory_tools' se cargan al inicio. Los demás módulos se descargan tras 5 minutos de inactividad, previniendo el desbordamiento del contexto del LLM.

Semantic Router

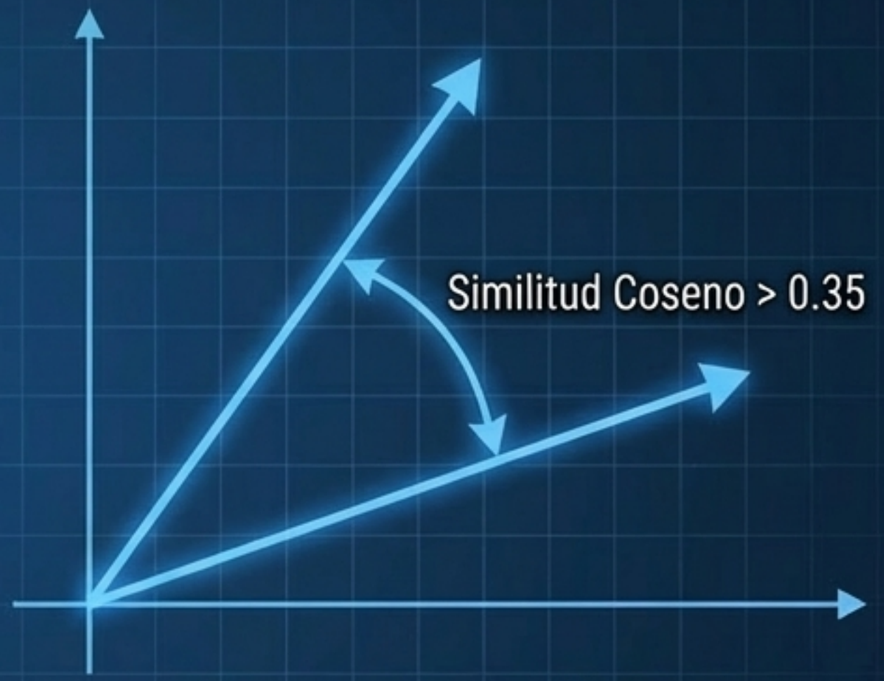

Los agentes no necesitan conocer el nombre exacto de la herramienta. El sistema mapea intenciones a través de embeddings locales, utilizando precisión matemática estricta para enrutar tareas sin falsos positivos.

NotebookLM

Infraestructura Cognitiva I: HybridMemory

Memoria Persistente 100% Local sobre SQLite

Cero llamadas a APIs externas. El sistema clasifica y combina los mejores resultados matemáticamente sin necesidad de entrenar un modelo de re-ordenamiento (reranking).

NotebookLM

Infraestructura Cognitiva II: SilvaDB & Olvido Biológico

Grafo de Conocimiento con Decaimiento Visual de Relevancia

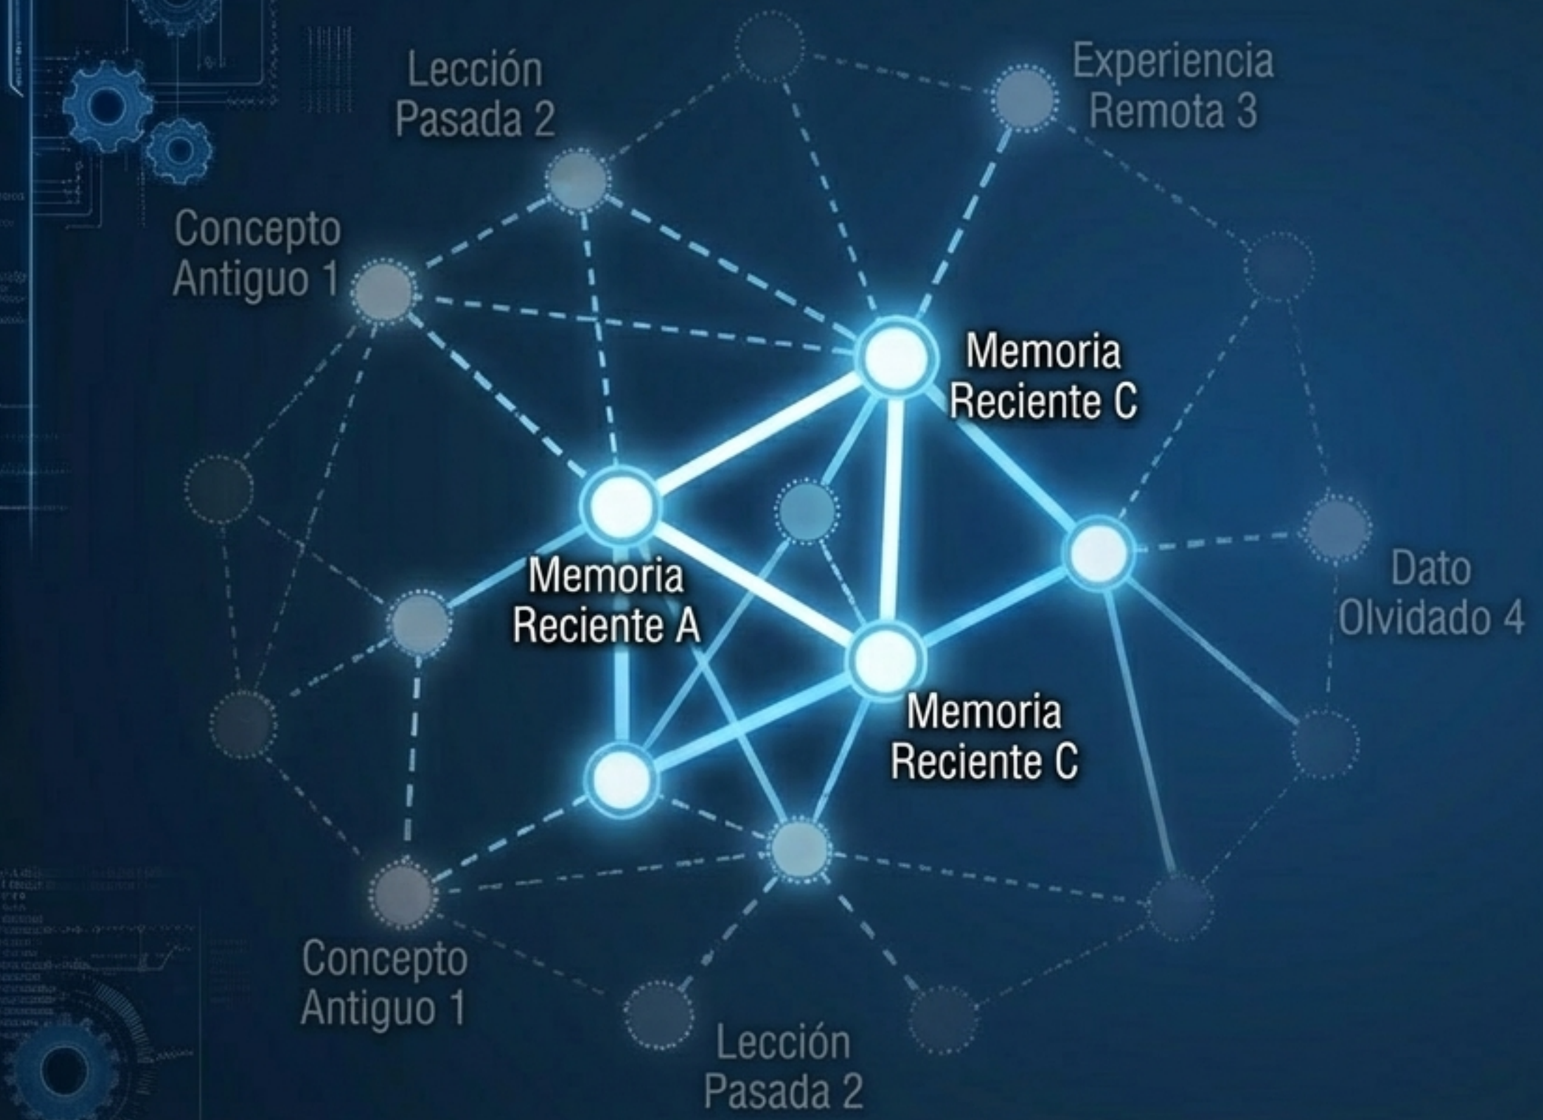

Grafo de Conocimiento (BFS):
Mapea lecciones, conceptos y experiencias. Utiliza algoritmos de Búsqueda en Anchura (Breadth-First Search) para recuperar contexto multi-salto.

Agent Mailbox:
Sistema de mensajería asíncrona entre sub-agentes integrado directamente en el grafo.

Decaimiento de Pesos (Weight Decay):
Simula el 'olvido biológico' reduciendo gradualmente la relevancia de los recuerdos antiguos. Previene la contaminación crónica de la ventana de contexto.

NotebookLM

Arquitectura de Seguridad: ExecutionGuard

Defensa en Profundidad sin sacrificar soberanía

Flujo de Petición Segura

Las peticiones desde canales no confiables (HTTP sin autenticar) tienen bloqueado el acceso a DANGEROUS_TOOLS (ej. bash).

Límite estricto de 60 llamadas por minuto por sesión.

Una máquina de estados protege contra cascadas de errores. Tras 3 fallos consecutivos, el disyuntor se abre y bloquea la herramienta por 30 segundos.

NotebookLM

Auditoría Técnica: La Realidad vs. El Hype

Generar confianza a través de la transparencia radical.

Afirmación de Marketing	⚠ Realidad Técnica ⚠
Es un Sistema Operativo (OS).	Es un Agent Runtime Environment. No tiene bootloader ni scheduler de kernel tradicional.
Memoria GraphRAG.	Es un Grafo de Conocimiento con BFS traversal. Faltan algoritmos de detección de comunidades (Louvain/Leiden) y sumarización jerárquica.
Sandboxing Seguro.	El “bash_expert” usa pattern blocking (listas negras). No es un aislamiento real a nivel de kernel tipo gvisor.

NotebookLM

Límites Arquitectónicos: Dónde se Rompe ForjaMCP

Generar confianza a través de la transparencia radical.

Cuellos de Botella de Hilo Único

Al correr sobre Node.js, las operaciones pesadas de I/O (orquestar ComfyUI) pueden bloquear el event loop si no se manejan con timeouts.

Contención de Escritura (SQLite WAL)

Excelentes lecturas concurrentes, pero escrituras simultáneas (métricas, logs, thought chains) provocarán errores SQLITE_BUSY.

Optimización de Máquina Única

Diseñado para 1-10 usuarios. NO posee aislamiento robusto para entornos multi-tenant (SaaS empresarial) ni Alta Disponibilidad (HA).

NotebookLM

Roadmap de Ingeniería (2026-2027)

Generar confianza a través de la transparencia radical.

Q2 2026 → Q3 2026 → Q4 2026

Q2 2026 (Actual)

- Stable Local OS
- Triple Transporte MCP
- HybridMemory con RRF

Q3 2026 (Rendimiento)

- Inferencia de embeddings a Worker Threads (evitar OOM)
- Automatización nativa de Weight Decay
- Dashboard de observabilidad (Prometheus-style)

Q4 2026 (Escalabilidad)

- Multi-Hub P2P Mesh utilizando libp2p
- Nomad Agents transfiriendo estado y contexto entre nodos físicos

NotebookLM

Síntesis: El Sovereign Compute Stack

Generar confianza a través de la transparencia radical.

La Física de la IA Agéntica ha Cambiado.

- Al eliminar el viaje de 200ms a la nube, ForjaMCP transforma componentes aislados en un bucle de retroalimentación en tiempo real.
- El agente ya no es un “cliente” esperando respuestas de un servidor distante. Es un organismo local unificado, privado, modular y auto-gestionado.
- La latencia cero no es solo una métrica; es un nuevo paradigma cognitivo para las máquinas.

NotebookLM

Engineering Closure

```
$ git clone https://github.com/forjamcp/core.git
$ npm install && npm start

> [ForjaMCP] Micro-kernel initialized. 24 Guilds ready.
> [Latency Profile] 3ms local loop established.
```

Soberano. Estable. Audit-Ready. Clona el repositorio. Audita el código.
Mide la latencia. El futuro de la IA agéntica se forja localmente.

NotebookLM